

Attention과 AutoEncoder

연준모

-
- 1. Attention
 - 2. AutoEncoder

Attention?

들어오는 데이터의 양은 엄청나게 많다

특히, 시퀀스 데이터는 입력 데이터가 많으면 먼저 들어온 정보가 소실된다는 것을 우리는 배웠다.(RNN)

Attention은 모든 정보를 동일하게 보지 않고, 현재 작업과 **관련된 중요한 정보에만 집중**하여
가중치를 부여하는 방법이다

이는, 데이터 베이스 검색과 유사한데, 다음과 같은 값을 사용해서 계산하게 된다

Query (Q) : 내가 찾고자 하는 정보 (검색어)

Key (K) : 검색 대상이 되는 정보의 식별자 (데이터베이스의 인덱스)

Value (V) : 식별자에 해당하는 실제 정보 (데이터베이스의 내용)

Q가 모든 K와 얼마나 유사한지(관련 있는지) 계산하고, 이 유사도를 가중치로
삼아 V들의 중합을 계산한다.

Attention?

일반적으로(특히 Attention이 주로 사용되는 Transformer에선) 행렬곱으로 이루어 진다

Q (Query 행렬): (N_q, d_k) - N_q 개의 쿼리 벡터

K (Key 행렬): (N_k, d_k) - N_k 개의 키 벡터

V (Value 행렬): (N_k, d_v) - N_k 개의 밸류 벡터

Transformer 모델에선 Self-Attention을 사용하게 되는데,(다음주 예정), 여기서는

Q, K, V 가 모두 동일한 입력 X 에 각각 다른 가중치 행렬 W_Q, W_K, W_V 를 곱하여 생성된다.

$Q = XW_Q, K = XW_K, V = XW_V$. 여기서 W 행렬들은 X 를 다른 기저로 투영하는 선형 변환 이다.

1. Attention 정규화?

ONECLICK AI

Attention?

식은 다음과 같다

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

비유

V = 도서관에 있는 모든 책의 내용 그 자체

K = 모든 책의 제목, 키워드

Q = 나의 리포트 주제 (고양이와 관련된 역사)

1단계: 유사도 계산

$$Scores = QK^T$$

연산 : Q (N_q, d_k) 행렬과 K 의 전치(Transpose) 행렬 K^T (d_k, N_k)의 곱.

결과 : $scores$ 행렬 (N_q, N_k).

이 행렬 곱의 결과 $Scores_{ij}$ 는 i번째 쿼리 벡터 q_i 와 j번째 키 벡터 k_j 의 내적이다.

$$Scores_{ij} = q_i \cdot k_j$$

벡터 내적 $a \cdot b = \|a\| \|b\| \cos(\theta)$ 는 두 벡터의 유사도(Similarity)를 측정한다
 q_i 와 k_j 가 얼마나 정렬되어 있는지(방향이 비슷한지)를 나타낸다

Attention?

1단계: 유사도 계산

$$Scores = QK^T$$

모든 Q와 모든 K를 한 번에 비교하는 매우 효율적인 방법

세로 백터 Q와 전치를 통해 가로가 된 가로백터 K의 곱 => 모든 원소 조합에 대한 연산 가능

$$Scores_{ij} = q_i \cdot k_j \quad \text{내적을 해야 얼마나 유사한지 측정할 수 있다}$$

(내 주제 : 고양이와 관련된 역사) · (책 제목 : 고양이의 역사) => 높은 점수(90 점)

(내 주제 : 고양이와 관련된 역사) · (책 제목 : 군주론) => 낮은 점수(15점)

Attention?

2단계: 가중치 계산 with Softmax

$$A = \text{softmax}\left(\frac{\text{Scores}}{\sqrt{d_k}}\right)$$

연산 : 스케일링: Scores 행렬의 모든 요소를 $\sqrt{d_k}$ 로 나눈다.

이는 내적 값이 너무 커져서 Softmax의 기울기가 0이 되는 것을 방지하기 위한 안정화 장치이다.

점수(90)가 너무 크면, Softmax가 "이 책 100%, 나머지 0%"처럼 너무 극단적인 결과가 나온다

$\sqrt{d_k}$ (키 벡터의 차원)라는 값으로 점수들을 나눠서, 점수 차이를 진정시키는 **안정화 장치**

(예: 90 → 9.0, 15 → 1.5)

Softmax: 스케일링된 Scores 행렬의 각 행에 대해 Softmax 를 적용한다

(9.0, 1.5) → (85%, 15%)

고양이의 역사 책에 85% 집중하고, 군주론 책에는 15%만 집중하라는 명확한 집중도 레시피가 만들어 진다

Attention?

2단계: 가중치 계산 with Softmax

결과: A (Attention Weight 행렬) (N_q, N_k).

Softmax는 각 행의 값(q_i 가 모든 k_j 와 갖는 유사도 점수)을 0과 1 사이의 값으로 정규화하며,
각 행의 합이 1이 되도록 만든다는 것을 우리는 이미 알고 있다.

A_{ij} 는 i 번째 쿼리가 j 번째 밸류에 얼마나 집중해야 하는지를 나타내는 확률적 가중치가 된다.

Attention?

3단계: 가중치 계산

$$\text{Output} = A \cdot V$$

연산: A (N_q, N_k) 행렬과 V (N_k, d_v) 행렬의 곱.

A : 2 단계에서 만든 집중도 레시피(Softmax 출력)

V : 실제 책의 내용물

둘을 곱하므로 가중평균을 만든다

$$\text{Output}_i = \sum A_{ij} v_j$$

고양이의 역사 내용 85% + 군주론 15%

이는 고양이라는 단어의 의미를 군주론 관점까지 고려하여 풍부하게 재해석한 결과물이 나온다

Attention?

결과: *Output* 행렬 (N_q, d_v).

이것이 어텐션의 최종 결과물이다.

*Output*의 i 번째 행 $Output_i$ 는 V 행렬의 모든 행 v_j (밸류 벡터)들의 가중 평균(Weighted Average)으로 계산된다.

$$Output_i = \sum_{j=1}^{N_k} A_{ij} v_j$$

즉, i 번째 쿼리(q_i)에 대한 응답($Output_i$)은, q_i 와의 관련도(A_{ij})가 높은 밸류(v_j)는 많이 가져오고 관련도가 낮은 밸류는 적게 가져와 모두 합친 **정보의 종합** 벡터이다.

Attention?

결론

1. Q(내 질문)가 K(키워드)와 얼마나 비슷한지 점수를 매기고 (1단계: QK^T)
2. 이 점수를 집중할 비율(%)로 변환한 뒤 (2단계: Softmax)
3. 이 비율(A)대로 V(실제 내용물)들을 섞어서 새로운 종합 정보(Output)를 만드는 과정

Attention?

결론

어텐션은 내적(Dot Product)을 통해 유사도를 측정하고, 이 유사도를 가중치 삼아 행렬 곱을 통해
가중합을 계산하는, 미분 가능한 정보 추출 메커니즘이다.
모든 과정이 행렬 연산으로 구성되어 GPU에서 매우 효율적으로 병렬 처리될 수 있다.

정보의 병목 현상(치매)을 해결하고 **장기 의존성(Long-Term Dependency)** 문제를 극복하기 위해서 존재한다
트랜스포머 등장 이후의 아키텍쳐에서 주로 사용한다.

다음 시간에, 이 어텐션의 발전형인 Self Attention, MHA, CLS 토큰 등을 알아볼 것이다.

또한, 실사용 시 SDPA, earge 가 있는데, 이 내용은 전부 트랜스포머 하면서 알아볼 것이다.

2. AutoEncoder 알아보기 어떻게 생겼을까?

ONECLICK AI

AutoEncoder

데이터의 효율적인 압축 표현(Representation) 학습을 위한 비지도 학습이다
대칭적인 U자형 구조와 스kip 연결(Skip Connections)을 핵심

인코더 (수축 경로)

입력 데이터 x 를 원본보다 훨씬 저차원인 잠재 벡터 z 로 압축

디코더 (확장 경로)

압축된 z 로부터 원본 x 와 최대한 유사한 \hat{x} 를 복원

스킵 연결 (인코더, 디코더를 연결)

<https://dl.acm.org/doi/10.5555/1756006.1953039>

<https://arxiv.org/abs/2102.08012>

AutoEncoder

핵심은 **병목(Bottleneck)z**.

z 가 x 를 완벽히 복원할 수 있으려면, z 는 x 의 가장 중요하고 본질적인 특징(essence)만을 담고 있게 된다

=> 단순 압축을 넘어 데이터의 기저에 깔린 **매니폴드(manifold)**를 학습하게 되는거다.

Manifold?

한마디로 매니폴드는 "데이터가 실제로 살아가는 숨겨진 저차원 공간" 또는 데이터의 본질적인 규칙(Rule)

3D 공간 속 A4 용지를 구겨 만든 공이 있다 했을 때,

구겨진 종이 표면이 바로 **2D 매니폴드**이다.

데이터: 우리가 가진 데이터는 이 구겨진 종이 위에만 찍힌 점들이다.

이게 뭔 말이냐 3차원 동간의 데이터는 3개의 값을 가진다(H, W, C)

데이터는 3D 공간에 흩어져 있는 것처럼 보이지만(고차원), 실제로는 2D 종이 표면(저차원 매니폴드)이라는 '규칙'을 따르고 있다.

Manifold In AutoEncoder?

입력 (x): '구겨진 종이' 위의 한 점의 **3D 좌표 (x, y, z)**.

(예: MNIST 이미지 784개 픽셀 값)

인코더 (Encoder): 이 3D 좌표를 보고, '구겨진 종이'를 쪽 펴서 이 점이 원래 종이의 어디에 있었는지 2D 좌표 (u, v)를 찾아낸다.

잠재 벡터 (z): 인코더가 찾아낸 **핵심 2D 좌표 (u, v)**. 이것이 바로 데이터의 '본질 (essence)'이다.

디코더 (Decoder): 2D 좌표 (u, v)를 받고, 종이를 **원래대로 다시 구겨서** 이 점의 3D 좌표 (x, y, z)를 복원한다.

데이터가 어떤 '규칙'(매니폴드)을 따르는지 학습

핵심 규칙'을 학습하고, 그것을 잠재 벡터 z 에 담아내는 것

AutoEncoder

- $\mathbf{x} \in R^d$: 입력 벡터 (예: Flatten된 이미지)
- $\mathbf{z} \in R^k$: 잠재 표현 (latent vector), \mathbf{z} 가 위치한 공간을 **잠재 공간(Latent Space)**이라 부른다.
- **병목 제약 (Bottleneck Constraint)**: 핵심은 $k \ll d$ (undercomplete)이다.
- 이는 모델이 \mathbf{x} 를 단순히 복사하는 항등 함수($\hat{\mathbf{x}} = \mathbf{x}$)를 배우는 것을 방지하고,
- 유의미한 정보만 압축하도록 강제한다.
- $\hat{\mathbf{x}} \in R^d$: 재구성 출력
- $\theta = \{\mathbf{W}_e^{(l)}, \mathbf{b}_e^{(l)}\}, \phi = \{\mathbf{W}_d^{(m)}, \mathbf{b}_d^{(m)}\}$: 인코더와 디코더의 학습 가능한 파라미터 (가중치 및 편향)

AutoEncoder

1. 인코더 입력 전 데이터 전처리

$$\mathbf{X} \in R^{C \times H \times W} \quad \text{-- flatten --} \rightarrow \mathbf{x} = \text{vec}(\mathbf{X}) \in R^d, \quad d = C \cdot H \cdot W$$

예: MNIST $28 \times 28 \times 1 \rightarrow \mathbf{x} \in R^{784}$

이미지를 1자로 길게 편다

공간적 위계(spatial hierarchy)와 지역성(locality) 정보가 소실

AutoEncoder

2. Encoder \mathbf{z} 는 입력 데이터 \mathbf{x} 가 여러 개의 '압축 레이어(Dense)'를 통과하며 만들어진 **최종 요약 벡터**

L 개의 Dense 레이어가 들어가게 된다.

$$\mathbf{h}^{(0)} = \mathbf{x} \in \mathbb{R}^{d_0}, \quad d_0 = d$$

$$\mathbf{h}^{(1)} = \sigma_1 (\mathbf{W}_1 \mathbf{h}^{(0)} + \mathbf{b}_1) \in \mathbb{R}^{d_1}$$

$$\mathbf{h}^{(2)} = \sigma_2 (\mathbf{W}_2 \mathbf{h}^{(1)} + \mathbf{b}_2) \in \mathbb{R}^{d_2}$$

⋮

$$\mathbf{z} = \mathbf{h}^{(L)} = \mathbf{W}_L \mathbf{h}^{(L-1)} + \mathbf{b}_L \in \mathbb{R}^k$$

- $\mathbf{W}_\ell \in R^{d_\ell \times d_{\ell-1}}, d_\ell < d_{\ell-1} \rightarrow$ 차원 감소
- σ_ℓ : ReLU, Tanh, Sigmoid 등의 **비선형 활성화 함수**
- 마지막 레이어는 \mathbf{z} 가 연속적인 값의 범위를 가질 수 있도록 **활성화 함수가 없거나(선형)** Tanh를 사용하기도 한다.

2. AutoEncoder 알아보기 어떻게 생겼을까?

ONECLICK AI

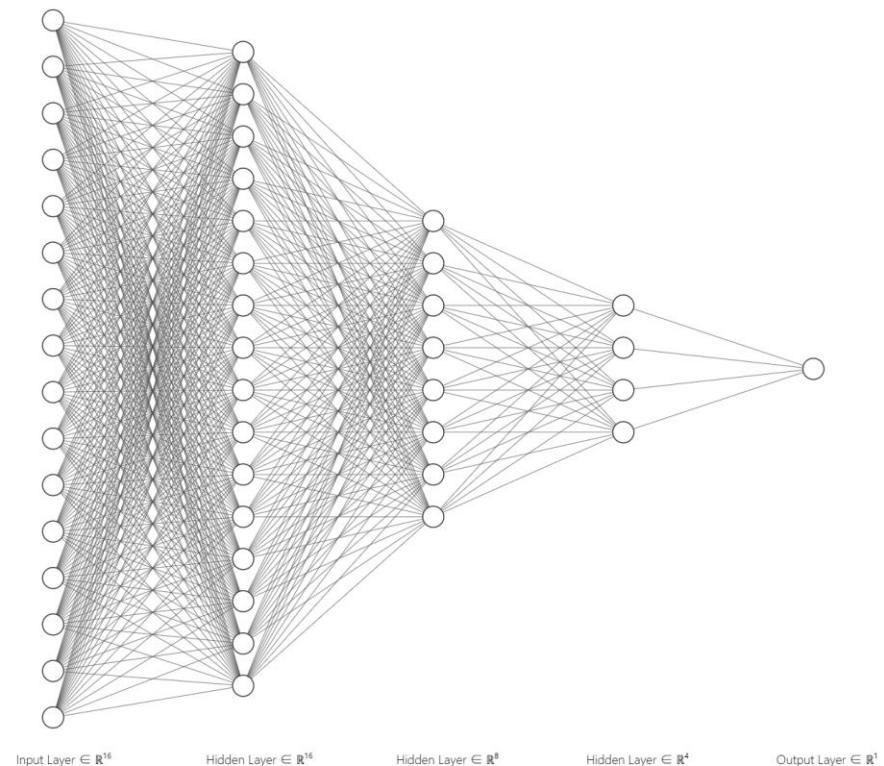
AutoEncoder

2. Encoder

? Dense Layer로 어떻게 차원을 축소하나요?

다음 레이어의 노드를 줄여버리면 된답니다!

Epoch가 진행되면서 좁은 길'을 통과하기 위해
스스로 가장 효율적인 형태(핵심 요약)로 변할
수밖에 없다



z는 '복사본'이 아닌 '가장 유의미한 정보'를 담도록 강제된다.
"어떻게든 32개 숫자 안에 원본의 핵심을 담아 디코더에게 전달해야 하기 때문이다."

AutoEncoder

2. Encoder

비선형성(σ)이 왜 필수적인가?

만약 모든 활성화 함수 σ 가 선형(즉, $\sigma(x) = cx$)이라면, L개의 레이어로 구성된 인코더 $f_\theta(\mathbf{x})$ 전체는 $\mathbf{W}_L \cdots \mathbf{W}_1 \mathbf{x} + \mathbf{b}'$ 형태의 단일 선형 변환으로 축약된다

L개의 레이어를 쌓아도 결국 1개의 레이어를 쓴 것과 똑같아 진다

$$f_\theta(\mathbf{x}) = \mathbf{W}_E \mathbf{x} + \mathbf{b}_E \quad g_\phi(\mathbf{z}) = \mathbf{W}_D \mathbf{z} + \mathbf{b}_D$$

$$\hat{\mathbf{x}} = g_\phi(f_\theta(\mathbf{x})) = \mathbf{W}_D(\mathbf{W}_E \mathbf{x} + \mathbf{b}_E) + \mathbf{b}_D = (\mathbf{W}_D \mathbf{W}_E) \mathbf{x} + (\mathbf{W}_D \mathbf{b}_E + \mathbf{b}_D) = \mathbf{W}' \mathbf{x} + \mathbf{b}'$$

이는 손실 함수로 MSE를 사용할 경우,

데이터를 가장 잘 표현하는 k차원의 초평면을 찾는 **PCA(주성분 분석)**와 동일해 진다.

비선형 활성화 함수는 AE가 PCA를 넘어

훨씬 더 복잡하고 강력한 비선형 매니폴드를 학습할 수 있게 하는 핵심이다

AutoEncoder

2. Decoder

$$\tilde{\mathbf{h}}^{(0)} = \mathbf{z} \in \mathbb{R}^k$$

$$\tilde{\mathbf{h}}^{(1)} = \sigma'_1 \left(\mathbf{W}'_1 \tilde{\mathbf{h}}^{(0)} + \mathbf{b}'_1 \right) \in \mathbb{R}^{d_{M-1}}$$

⋮

$$\hat{\mathbf{x}} = \sigma_{\text{out}} \left(\mathbf{W}'_M \tilde{\mathbf{h}}^{(M-1)} + \mathbf{b}'_M \right) \in \mathbb{R}^d$$

이 32개 숫자를 어떻게 256개로 펼칠지"에 대한 복원 노하우이며,
이 역시 학습을 통해 얻어진다

대칭 구조 (Mirrored Structure): 일반적으로 디코더는 인코더의 구조를 역순으로 뒤집은 형태 ($d \rightarrow 256 \rightarrow 32$ 였으면 $32 \rightarrow 256 \rightarrow d$)를 가진다.

가중치 공유 (Tied Weights): 때때로 디코더의 가중치를 인코더 가중치의 전치(transpose)로 설정하는 제약($\mathbf{W}'_\ell = \mathbf{W}_{L-\ell+1}^T$)을 주기도 한다. 이는 파라미터 수를 절반으로 줄여 과적합을 방지하는 데 도움이 된다.

AutoEncoder

2. Decoder

1차원 백터를 2D 이미지로 복원 한 후,

σ_{out} : 출력 활성화 함수. 입력 x 의 스케일에 따라 결정된다. 같아야 비교할 수 있다.

$x \in [0,1]$ (예: 정규화된 이미지) → **Sigmoid** (예: 정규화된 흑백)

$x \in [-1,1]$ (예: Tanh 정규화) → **Tanh**

$x \in R$ (예: 일반적인 실수 데이터) → **선형 (활성화 없음)** (예: -5.4, 102.1)

AutoEncoder

$$\mathcal{L}(\mathbf{x}, \hat{\mathbf{x}}) = \begin{cases} \frac{1}{d} \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2 = \frac{1}{d} \sum_{i=1}^d (x_i - \hat{x}_i)^2 & \text{MSE()} \\ -\frac{1}{d} \sum_{i=1}^d [x_i \log \hat{x}_i + (1 - x_i) \log(1 - \hat{x}_i)] & \text{BCE()} \end{cases}$$

사실상 틀린그림 찾기

1. **MSE (L2 Loss):** 재구성 오차가 **가우시안 분포(Gaussian distribution)**를 따른다고 가정하는 것과 같다.
즉, $p(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mathbf{x}|g_\phi(\mathbf{z}), \sigma^2 \mathbf{I})$ 를 가정하고 Likelihood를 최대화하는 것과 같다.
이는 실수 값(real-valued) 데이터에 적합하다.

784개 모든 픽셀을 1:1로 비교해서 (원본 픽셀 - 복원 픽
셀)²의 평균 오류를 낸다

일반적인 실수 값 데이터(예: 소리, 주가)에 적합

AutoEncoder

2. **BCE (Cross-Entropy)**: 입력 데이터 \mathbf{x} 의 각 픽셀 x_i 가 베르누이 분포(Bernoulli distribution)(즉, 0 또는 1)를 따른다고 가정하는 것과 같다.

이는 픽셀 값이 [0, 1] 범위 (확률로 해석)인 이진화된 이미지나 Sigmoid 출력에 적합하다.

픽셀 값이 0 아니면 1에 가까운 '확률'일 때 사용한다. (예: 흑백 이미지) "이 픽셀이 '흰색일 확률'이 0.9라고 예측했는데, 정답(원본)이 1(흰색)이네? 잘했어."라고 점수를 준다

Sigmoid를 사용한 [0, 1] 범위의 이미지에 적합

목적: $\min_{\theta, \phi} \mathcal{L}(\mathbf{x}, g_\phi(f_\theta(\mathbf{x})))$

$\hat{\mathbf{x}} \approx \mathbf{x}$ 가 되도록 θ 와 ϕ 를 최적화 한다.

이는 \mathbf{z} 가 \mathbf{x} 의 **핵심 정보(압축된 표현)**를 성공적으로 보유해야 함을 의미한다.

AutoEncoder

역전파

손실 함수 \mathcal{L} 을 최소화하기 위해, \mathcal{L} 을 θ 와 ϕ 의 모든 파라미터(가중치, 편향)로 편미분하여 그래디언트를 계산

1. **출력 → 디코더** : $\frac{\partial \mathcal{L}}{\partial \hat{\mathbf{x}}}$ (손실의 그래디언트)가 계산
2. 이 그래디언트는 디코더의 마지막 레이어 \mathbf{W}'_M 부터 역으로 전파되며 ϕ (디코더 가중치)를 업데이트

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}'_M} = \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{x}}} \frac{\partial \hat{\mathbf{x}}}{\partial \mathbf{W}'_M}$$

AutoEncoder

역전파

3. 그래디언트는 \mathbf{z} 까지 도달합니다. $\frac{\partial \mathcal{L}}{\partial \mathbf{z}}$
4. \mathbf{z} 에 도달한 그래디언트는 이제 인코더를 역으로 통과하며 θ (인코더 가중치)를 업데이트 한다.
$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}_L} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}} \frac{\partial \mathbf{z}}{\partial \mathbf{w}_L}$$

SGD/Adam과 같은 옵티마이저는 이 그래디언트를 사용하여 파라미터를 갱신한다.

$$\theta \leftarrow \theta - \eta \frac{\partial \mathcal{L}}{\partial \theta}$$
$$\phi \leftarrow \phi - \eta \frac{\partial \mathcal{L}}{\partial \phi} \text{ (여기서 } \eta \text{는 학습률)}$$

2. AutoEncoder 알아보기 어떻게 생겼을까?

ONECLICK AI

AutoEncoder

레이어	입력 (차원)	출력 (차원)	비고
Input	[1, 28, 28]	-	원본 이미지 (채널, 높이, 너비)
Flatten	[1, 28, 28]	[784]	[cite_start]2D 이미지를 1D 벡터로 편 [cite: 101, 103]
(Encoder)			
Dense 1	784	256	[cite_start]첫 번째 은닉층 (차원 축소) [cite: 111]
ReLU 1	256	256	[cite_start]비선형 활성화 함수 [cite: 116]
Dense 2 (z)	256	32	[cite_start]z (잠재 벡터, 병목) [cite: 93, 115]
(Decoder)			
Dense 3	32	256	디코더 첫 번째 은닉층
ReLU 2	256	256	
Dense 4	256	784	원본 벡터 차원으로 복원
Reshape	[784]	[1, 28, 28]	1D 벡터를 2D 이미지로 재구성
Sigmoid	[1, 28, 28]	[1, 28, 28]	[cite_start] \hat{X} (복원된 이미지) [cite: 158, 159]

AutoEncoder

예제: MNIST Dense AE ($784 \rightarrow 32 \rightarrow 784$)

<https://huggingface.co/gihakkk/AutoEncoder/tree/main>

AutoEncoder

아니 근데 그래서 결국 이미지인데 위치정보 소실되면 안 되는거 아닌가요?

맞아요 그래서 CNN AutoEncoder가 있습니다

<https://arxiv.org/abs/1611.09119>

2. AutoEncoder 알아보기 어떻게 생겼을까?

ONECLICK AI

CNN AutoEncoder

항목	Dense AE	CNN AE
입력	1D 벡터 [B, D]	4D 텐서 [B, C, H, W]
공간 구조	소실(Flatten)	유지 및 활용
압축 방식	뉴런 수 감소(차원 수)	공간 해상도(H, W)감소 + 채널 증가(특징 추출)
파라미터	많음(Fully-Connected)	적음(Parameter Sharing)
핵심연산	행렬 곱	합성 곱

1. **파라미터 공유 (Parameter Sharing)** : 하나의 필터(W_k)가 이미지의 모든 위치를 순회하며 동일한 특징(예: 수직선)을 감지한다. 이로 인해 Dense AE보다 파라미터 수가 훨씬 적어 효율적이고 과적합 위험이 낮다.

2. **번역 불변성 (Translation Invariance)** : 물체가 이미지의 왼쪽 위에 있든 오른쪽 아래에 있든 동일한 필터가 활성화 된다. 이는 공간적 정보를 보존하는 데 매우 강력하다.

CNN AutoEncoder

Dense에선 Flatten 했지만, 여기선 그런거 없이 바로 들어간다.
바로 이미지가 Encoder로 들어가는거다

Encoder는 CNN 그 자체로,

우리가 매 주 하고 있는 [Conv + ReLU -> Maxpolling]를 반복 -> Flatten -> Dense -> z

Decoder도 방식이 여러 개가 있는데,

저번주 U-Net 할 때 했던 **ConvTranspose**와

Upsampling + Conv가 있다.

https://gihak111.github.io/ai/2025/11/13/Upsampling_Conv_upload.html

2. AutoEncoder 알아보기 어떻게 생겼을까?

ONECLICK AI

CNN AutoEncoder

예제: MNIST CNN AE

<https://huggingface.co/gihakkk/AutoEncoder/tree/main>

제공된 표의 ConvT 레이어는 계산이 정확히 28x28로 떨어지도록 커널/스트라이드/패딩을 조정해야 한다

레이어	입력	출력	비고
Input	[1,28,28]	-	-
Conv1	[1,28,28]	[16,26,26]	3×3 , pad=0, C: 1→16
ReLU	-	-	-
MaxPool	[16,26,26]	[16,13,13]	2×2 , H/W: 26→13
Conv2	[16,13,13]	[32,11,11]	3×3 , C: 16→32
ReLU	-	-	-
MaxPool	[32,11,11]	[32,5,5]	2×2 , H/W: 11→5
Flatten	[32×5×5]	[800]	-
Dense	800	32	z
(Decoder)			
Dense	32	800	-
Reshape	[800]	[32,5,5]	-
ConvT1	[32,5,5]	[16,11,11]	3×3 , stride=2, pad=1 (조정됨)
ConvT2	[16,11,11]	[1,28,28]	3×3 , stride=3, pad=1 (조정됨)
Sigmoid	-	[1,28,28]	(\hat{\mathbf{X}})

2. AutoEncoder 알아보기 어떻게 생겼을까?

ONECLICK AI

CNN AutoEncoder

예제: MNIST CNN AE

```
C:\Users\yeonj\OneDrive\바탕 화면\AI 커리큘럼\6. Attention과 AutoEncoder>python CNN_AutoEncoder.py
원본 데이터(x) shape: torch.Size([64, 1, 28, 28])
압축된 잠재 벡터(z) shape: torch.Size([64, 32])
복원된 데이터(x_hat) shape: torch.Size([64, 1, 28, 28])

계산된 손실(BCELoss): 0.694730281829834
역전파 완료
```

```
C:\Users\yeonj\OneDrive\바탕 화면\AI 커리큘럼\6. Attention과 AutoEncoder>python Autoencoder.py
원본 데이터(x) shape: torch.Size([64, 784])
압축된 잠재 벡터(z) shape: torch.Size([64, 32])
복원된 데이터(x_hat) shape: torch.Size([64, 784])

계산된 손실(MSELoss): 0.9956663250923157
역전파 완료
```

CNN AutoEncoder

어 근데 CNN AE 하는건 좋은데 오늘 Attention 했잖아요
이건 AutoEncoder랑 안쓰나요?

그래서 Attention AutoEncoder가 있습니다.

궁금하다면, 아래 링크에서 확인해 주세요

<https://www.proquest.com/docview/2618269233?sourceType=Scholarly%20Journals>

또한, 다양한 오토인코더가 궁금하다면?

https://gihak111.github.io/ai/2025/11/13/many_Autoencoder_upload.html

감사합니다